

Booking.com 社群文字特徵與互動成效完整結果報告

第 4.0.0 版（控制變數改為 0/1 虛擬變數）

產出時間：2026 年 4 月 29 日

2026 年 4 月 29 日

目錄

執行摘要	2
1 研究架構	2
1.1 研究問題	2
1.2 研究假說	2
1.3 模型規格	2
2 資料說明	3
2.1 資料集特徵	3
2.2 變數定義	4
2.3 文字前處理流程	4
3 敘述統計	6
3.1 摘要統計	6
3.2 二元變數頻率分布	6
3.3 重點觀察	6

目錄	2
4 相關分析	7
4.1 Pearson 相關矩陣	7
4.2 重點相關發現	7
5 迴歸分析	8
5.1 估計方法	8
5.2 模型診斷	8
5.2.1 異質變異數 (Breusch–Pagan)	8
5.2.2 殘差常態性 (Shapiro–Wilk)	8
5.2.3 多元共線性 (VIF)	8
5.3 主迴歸結果	9
5.4 假說檢定	9
5.5 係數解讀	10
6 視覺化診斷	11
6.1 殘差分析	11
6.2 依問號分組之分布	12
7 與 v2.0.0 基準之比較	13
8 管理意涵	13
8.1 給 Booking.com 的建議	13
8.2 最佳化貼文範本	14
9 研究限制與未來方向	14
10 結論	14
A 技術附錄	14
A.1 軟體與套件	14
A.2 資料檔案	14

目錄	3
參考文獻	15

執行摘要

本報告呈現 Booking.com 社群媒體互動研究第 4.0.0 版之完整統計結果。所有分析皆使用 Python 統計腳本，並以異質變異數穩健 (HC1) 標準誤推論。相對於 v2.0.0 基準 (資料夾 20260330_151218)，第 4.0.0 版唯一的方法論調整，是將三個控制變數 (圖片、URL、@ 提及) 由原始計數改為二元虛擬變數 (出現／不出現)。在相同的 $N = 766$ 樣本下，這項單一更動使模型 R^2 從 0.4924 提升至 0.5119 (調整後 R^2 從 0.4871 提升至 0.5068)，所有 VIF 仍維持在 2.0 以下，且五項焦點假說的方向與顯著性皆未變動。

更動的理論動機在於：在微網誌平台上，能否抓住讀者注意力的關鍵，是貼文是否帶有圖片、連結或提及，而非數量多寡。將控制變數操作化為虛擬變數，可避免少數多附件貼文造成的雜訊，並讓更多變異被歸因於焦點文字特徵。

1 研究架構

1.1 研究問題

Booking.com 在 X 上的貼文文字特徵，如何影響社群互動表現？

1.2 研究假說

本研究檢驗以下五項焦點假說：

- H1. 文字長度與社群互動呈正相關。
- H2. 問號使用與社群互動呈正相關。
- H3. 情緒效價與社群互動呈正相關。
- H4. Hashtag 數量與社群互動呈正相關。
- H5. Emoji 使用與社群互動呈正相關。

1.3 模型規格

本研究估計以下迴歸式：

$$\begin{aligned} \ln(1 + \text{Engagement}_i) = & \beta_0 + \beta_1 \text{TextLength}_i + \beta_2 \text{Question}_i + \beta_3 \text{Valence}_i \\ & + \beta_4 \text{Hashtag}_i + \beta_5 \text{Emoji}_i + \beta_6 \text{PictureD}_i + \beta_7 \text{URLD}_i \\ & + \beta_8 \text{AtMentionD}_i + \varepsilon_i \end{aligned} \quad (1)$$

其中：

- $\text{Engagement}_i = \text{like}_i + \text{comment}_i + \text{share}_i$
- 應變數為自然對數轉換 $\ln(1 + \text{Engagement}_i)$ （以 `numpy.log1p` 計算），用以處理右偏並保留零互動觀察值。本報告所稱「log」皆指自然對數。
- 焦點自變數：TextLength（H1）、Question（H2）、Valence（H3）、Hashtag（H4）、Emoji（H5）。
- 控制變數（v4.0.0 改為 0/1 虛擬變數）：PictureD = $\mathbb{I}[\text{圖片數} > 0]$ 、URLD = $\mathbb{I}[\text{URL 數} > 0]$ 、AtMentionD = $\mathbb{I}[\text{@ 提及數} > 0]$ 。

係數解讀。 對於連續型自變數， X_k 每增加一單位，與 $(1 + \text{Engagement})$ 大致變動 $(e^{\beta_k} - 1) \times 100\%$ 。對於二元變數，相同公式對應「出現相對於不出現」的條件均值差距。當實際互動數遠大於 1 時，+1 偏移可忽略不計。

2 資料說明

2.1 資料集特徵

- **樣本數：** $N = 766$ ，皆為 Booking.com 官方 X 帳號之原創貼文。
- **時間範圍：**2021/11/01 至 2022/11/21。
- **資料來源：**data/research_data.csv（公開整理之資料集）。
- **欄位數：**38 欄，含原始互動指標、文字特徵與貼文層級附件。
- **過濾原則：**回覆、轉推與含影片之貼文已於資料集釋出前剔除；v4.0.0 不再施加任何列層過濾，以與 v2.0.0 之 $N = 766$ 完全一致。

2.2 變數定義

表 1: 變數定義與操作化

變數	角色	操作化定義
社群互動量	應變數	$\text{Engagement}_i = \text{like}_i + \text{comment}_i + \text{share}_i$ ，並取 $\ln(1 + \text{Engagement}_i)$ 處理右偏
文字長度	焦點自變數 (H1)	經六階段清理後最終字數 (<code>text_clean6</code>)，詳見 §2.3
問號	焦點自變數 (H2)	二元虛擬：原始貼文含至少一個「?」者為 1，否則為 0
情緒效價	焦點自變數 (H3)	字典法情感分數：將 token 與 1–9 效價字典 (Warriner 系 ANEW 擴展) 匹配後取均值並減去 4.5；正值為愉悅、負值為不悅；無匹配 token 之貼文記為 0
Hashtag 數量	焦點自變數 (H4)	原始貼文中 #tag 之數量
Emoji 數量	焦點自變數 (H5)	原始貼文中 emoji code-point 之數量
圖片 (0/1)	控制變數 (v4)	含至少一張圖片者為 1，否則為 0
URL (0/1)	控制變數 (v4)	含至少一個 URL 者為 1，否則為 0
@ 提及 (0/1)	控制變數 (v4)	含至少一個 @ 提及者為 1，否則為 0

何以採用虛擬變數？ 原 v2.0.0 規格使用原始計數。實證上，96% 以上貼文之圖片數為 0 或 1，URL 與 @ 提及之分布亦同樣集中於 {0, 1}。在此資料下，二元化能更貼近實際變異。理論上，「一張圖」與「兩張圖」之間的邊際差異難以獨立解讀；對於內容策略而言，真正具行動意義的對比，是「有附件」與「沒附件」。

2.3 文字前處理流程

原始貼文 `tweet_content` 依序經六階段清理 (`text_clean1`–`text_clean6`) 後，再計算 `length`、`valence` 與 `n-gram` 特徵：

1. `text_clean1`：移除 URL、@ 提及、#hashtag 與標記殘留，保留大小寫與 emoji。
2. `text_clean2`：移除驚嘆號（同步擷取 `exclamation` 計數）。
3. `text_clean3`：全部轉小寫。
4. `text_clean4`：移除剩餘標點與數字。

5. `text_clean5`: 移除英文停用詞 (NLTK / scikit-learn 標準清單)。
6. `text_clean6`: 最終清理結果; `length` 為以空白切分後之 token 數。

下游再對 `text_clean6` 進行斷詞與 Porter 詞幹化，最後與效價字典比對。最終僅 `length` 與 `valence` 進入迴歸；中介欄位保留以利稽核。

3 敘述統計

3.1 摘要統計

表 2: 敘述統計 ($N = 766$)

變數	平均	標準差	最小	Q1	中位數	Q3	最大	偏態
$\ln(1 + \text{Eng.})$	1.942	1.572	0.000	0.693	1.609	2.996	7.814	1.001
文字長度 (字)	23.453	12.257	0.000	14.000	22.000	33.000	53.000	0.239
問號 (0/1)	0.167	0.373	0.000	0.000	0.000	0.000	1.000	1.785
情緒效價	0.789	1.528	-3.352	0.000	0.000	2.046	3.948	0.371
Hashtag 數	0.145	0.489	0.000	0.000	0.000	0.000	3.000	3.817
Emoji 數	0.398	0.884	0.000	0.000	0.000	1.000	13.000	5.261
圖片 (0/1)	0.287	0.453	0.000	0.000	0.000	1.000	1.000	0.941
URL (0/1)	0.698	0.459	0.000	0.000	1.000	1.000	1.000	-0.865
@ 提及 (0/1)	0.080	0.271	0.000	0.000	0.000	0.000	1.000	3.105

3.2 二元變數頻率分布

表 3: 四項二元變數之頻率 ($N = 766$)

變數	0 (無)	%	1 (有)	%
問號	638	83.29	128	16.71
圖片 (0/1)	546	71.28	220	28.72
URL (0/1)	231	30.16	535	69.84
@ 提及 (0/1)	705	92.04	61	7.96

3.3 重點觀察

- **互動量分布**：log 轉換後仍右偏（偏態 1.001）；原始互動量極度右偏（偏態 7.67、最大值 2,474），故採 log 轉換。
- **文字長度**：平均 23.5 字（標準差 12.3），近似對稱（偏態 0.24）。
- **問號**：16.7% 之貼文含至少一個「？」。
- **Hashtag / Emoji**：皆稀疏（平均 < 0.5 ），絕大多數貼文不使用。
- **控制變數**：28.7% 之貼文含圖片，69.8% 含 URL，8.0% 含 @ 提及。

4 相關分析

4.1 Pearson 相關矩陣

表 4: Pearson 相關矩陣 (下三角; $N = 766$)

	(1)	(2)	(3)	(4)	(5)	(6)	(7)	(8)	(9)
(1) $\ln(1 + \text{Eng.})$	1								
(2) 文字長度	-0.184***	1							
(3) 問號	0.262***	-0.191***	1						
(4) 情緒效價	0.234***	0.150***	0.089*	1					
(5) Hashtag 數	0.452***	-0.012	0.075*	0.047	1				
(6) Emoji 數	0.411***	-0.044	0.206***	0.257***	0.087*	1			
(7) 圖片 (0/1)	0.481***	-0.042	0.172***	0.346***	0.042	0.439***	1		
(8) URL (0/1)	0.234***	0.035	-0.064	0.129***	0.084*	0.116**	0.417***	1	
(9) @ 提及 (0/1)	0.329***	0.016	0.010	0.033	0.495***	0.075*	-0.016	0.067	1

*** $p < .001$; ** $p < .01$; * $p < .05$ (雙尾)。

4.2 重點相關發現

- 文字長度負向關聯： $r = -0.184$ ， $p < .001$ ，預示 H1 將被否定。
- 最強的互動正相關：圖片虛擬變數 ($r = 0.481$)、Hashtag 數 ($r = 0.452$)、Emoji 數 ($r = 0.411$)。
- Hashtag 與 @ 提及虛擬變數： $r = 0.495$ ，為非對角線最大值；但兩者於迴歸中之 VIF 皆低於 1.4，未構成共線性問題。
- 所有相關係數 $|r| < 0.5$ ，與下文 VIF 分析一致。

5 迴歸分析

5.1 估計方法

模型以普通最小平方法 (OLS) 估計，並透過 `statsmodels.ols(...).fit(cov_type="HC1")` 套用 HC1 異質變異數穩健標準誤。Breusch–Pagan 檢定 (§5.2) 顯示存在顯著異質變異數，故全程採用 HC1 推論；點估計與一般 OLS 相同，僅標準誤、 t 值與 p 值有別。

5.2 模型診斷

5.2.1 異質變異數 (Breusch–Pagan)

- Lagrange Multiplier 統計量：90.22； $p < .0001$ 。
- F 統計量：12.63； $p < .0001$ 。
- 結論：存在顯著異質變異數，採 HC1 穩健標準誤合適。

5.2.2 殘差常態性 (Shapiro–Wilk)

- $W = 0.9680$ ； $p < .0001$ 。
- 結論：殘差略偏離常態；惟 $N = 766$ 已可仰賴 OLS 之漸近性質。

5.2.3 多元共線性 (VIF)

表 5: 變異數膨脹因子 (VIF)

變數	VIF
文字長度	1.077
問號	1.119
情緒效價	1.197
Hashtag 數	1.341
Emoji 數	1.303
圖片 (0/1)	1.639
URL (0/1)	1.259
@ 提及 (0/1)	1.338

所有 VIF 皆低於 2.0，遠低於 10 之常見門檻，無共線性疑慮。

5.3 主迴歸結果

表 6: 穩健 OLS 預測 $\ln(1 + \text{Engagement})$ 之結果 ($N = 766$)

變數	係數	穩健 SE	t 值	p 值
焦點自變數 (假說)				
文字長度 (H1)	-0.0193***	0.0032	-5.98	< .0001
問號 (H2)	0.4687***	0.1325	3.54	0.0004
情緒效價 (H3)	0.0641*	0.0266	2.41	0.0161
Hashtag 數 (H4)	1.0623***	0.1276	8.33	< .0001
Emoji 數 (H5)	0.3144***	0.0834	3.77	0.0002
控制變數 (v4.0.0 : 0/1 虛擬變數)				
圖片 (0/1)	1.1376***	0.1344	8.47	< .0001
URL (0/1)	0.1461	0.0868	1.68	0.0923
@ 提及 (0/1)	0.8898***	0.2433	3.66	0.0003
截距	1.4882***	0.1069	13.92	< .0001
模型配適				
觀察值數	766			
R^2	0.5119			
調整後 R^2	0.5068			
F 統計量	$F(8, 757) = 76.681, p < .0001$			

註：*** $p < .001$ 、** $p < .01$ 、* $p < .05$ (雙尾)；HC1 穩健標準誤。

5.4 假說檢定

表 7: 假說檢定結果摘要

假說	預測方向	估計值	結論
H1：文字長度	+	-0.019***	未獲支持
H2：問號	+	+0.469***	獲支持
H3：情緒效價	+	+0.064*	獲支持
H4：Hashtag 數	+	+1.062***	獲支持
H5：Emoji 數	+	+0.314***	獲支持

5.5 係數解讀

下列百分比效果均以 $(e^{\beta} - 1) \times 100\%$ 計算，意指其他變數不變下，預測變數每增加一單位（或從 0 變為 1）對 $(1 + \text{Engagement})$ 的相對變化。

H1：文字長度——未獲支持

$\beta_1 = -0.0193$ ， $p < .001$ 。每多一個經清理後的字，互動量約下降 -1.92% 。在 X 上「短勝於長」。

H2：問號——獲支持

$\beta_2 = +0.4687$ ， $p < .001$ 。含問號之貼文相較不含者，互動量約多出 $+59.8\%$ 。

H3：情緒效價——獲支持

$\beta_3 = +0.0641$ ， $p = .0161$ 。效價每提升一單位，互動量約增加 $+6.6\%$ 。

H4：Hashtag 數——獲支持

$\beta_4 = +1.0623$ ， $p < .001$ 。每多一個 hashtag，互動量約增加 $+189\%$ 。

H5：Emoji 數——獲支持

$\beta_5 = +0.3144$ ， $p < .001$ 。每多一個 emoji，互動量約增加 $+36.9\%$ 。

控制變數

圖片虛擬變數 ($\beta = +1.14$ ， $p < .001$ ，約 $+212\%$) 與 @ 提及虛擬變數 ($\beta = +0.89$ ， $p < .001$ ，約 $+143\%$) 皆呈強烈正向；URL 虛擬變數則小且不顯著 ($\beta = +0.15$ ， $p = .092$) ——由於 70% 的貼文本來就含 URL，「是否附帶連結」的邊際貢獻在納入其他特徵後並不顯著。

6 視覺化診斷

6.1 殘差分析




圖 1: 殘差分布與常態曲線疊圖




圖 2: 殘差 Q-Q 圖





圖 3: 殘差對配適值散布圖

6.2 依問號分組之分布

圖 4: 依問號分組之 $\ln(1 + \text{Engagement})$ 分布

7 與 v2.0.0 基準之比較

表 8: v2.0.0 (計數型 CV) vs. v4.0.0 (虛擬型 CV), 相同 $N = 766$

指標	v2.0.0	v4.0.0	Δ
R^2	0.4924	0.5119	+0.0195
調整後 R^2	0.4871	0.5068	+0.0197
F 統計量	63.857	76.681	+12.82
β_1 文字長度	-0.0211***	-0.0193***	+0.0018
β_2 問號	+0.4793***	+0.4687***	-0.0106
β_3 情緒效價	+0.0840**	+0.0641*	-0.0199
β_4 Hashtag	+1.0959***	+1.0623***	-0.0336
β_5 Emoji	+0.3428***	+0.3144***	-0.0284

控制變數重新編碼後， R^2 與調整後 R^2 各上升約 2 個百分點，F 統計量提升約 20%。所有焦點假說的方向與顯著性皆未變動；幅度上有微幅下移，這是預期內的結果（控制變數現以更乾淨的「是否出現」掌握共變，故焦點變數所吸收之變異略減）。控制變數中，圖片與 @ 提及虛擬變數係數明顯放大（因現為「無」對「有」的對比），URL 虛擬變數則失去顯著性，反映在已納入其他變數後，「是否附帶連結」本身已非主要差異化因子。

8 管理意涵

8.1 給 Booking.com 的建議

1. 擁抱簡潔。每多一字約損失 -1.9% 互動；建議鎖定 15-25 字。
2. 策略性提問。含「？」之貼文互動量約多出 +60%。
3. 維持正向情緒語調。效價每提升一單位增加約 +6.6% 互動。
4. 使用 hashtag。每一個 hashtag 約帶來 +189% 互動，槓桿極高，建議 1-2 個。
5. 使用 emoji。每一個 emoji 約帶來 +37% 互動，建議 1-2 個情境相關之表情符號。
6. 務必附圖。圖片虛擬變數係數對應約三倍以上互動。
7. 適時 @ 提及。@ 提及虛擬變數係數對應約 +143% 互動，可於合作目的地或飯店時運用。

8.2 最佳化貼文範本

理想之 Booking.com 貼文：精簡（15–20 字）、含問句、語氣正向、使用 1–2 個相關 hashtag、搭配 1–2 個情境化 emoji、附上圖片，並於合適場合 @ 提及合作夥伴。

9 研究限制與未來方向

- **橫斷面、觀察性資料**：本研究不主張因果，僅論及相關。
- **平台特定**：結果僅限 X 平台，未必可推至 Instagram、Facebook 或 TikTok。
- **單一品牌**：推廣至其他旅遊品牌或產業需另行驗證。
- **合計型互動指標**：like、comment、share 等權合計，未來可分項建模。
- **時間範圍**：2021–2022 年資料未必反映當下平台動能。

10 結論

第 4.0.0 版確認 v2.0.0 之質性結論——簡潔、互動性、正向語調、hashtag 與 emoji 皆與 Booking.com 在 X 上的互動量相關——並透過一項理論動機明確的單一更動（控制變數改為 0/1 虛擬變數），將模型 R^2 由 0.4924 提升至 0.5119。所有 VIF 仍維持在 2.0 以下，並全程採用 HCl 穩健標準誤以兼顧異質變異數下之推論有效性。

A 技術附錄

A.1 軟體與套件

- Python 3、pandas、numpy、scipy、statsmodels、matplotlib。
- 分析腳本：analysis/python/run_statistics.py (v4.0.0)。

A.2 資料檔案

- 輸入：data/research_data.csv (766 列 $\times$ 38 欄)。
- 輸出：results/20260429_014427/ (本版本)。

參考文獻

1. De Vries, L., Gensler, S., & Leeﬂang, P.S.H. (2012). Popularity of brand posts on brand fan pages: An investigation of the effects of social media marketing. *Journal of Interactive Marketing*, 26(2), 83–91.
2. Gkikas, D.C., Tzafilkou, K., Theodoridis, P.K., Garmpis, A., & Gkikas, M.C. (2022). How do text characteristics impact user engagement in social media posts? Modeling content readability, length, and hashtags number in Facebook. *International Journal of Information Management Data Insights*, 2, 100067.
3. Ko, E.E., Kim, D., & Kim, G. (2022). Influence of emojis on user engagement in brand-related user-generated content. *Computers in Human Behavior*.
4. Li, Y., & Xie, Y. (2020). Is a picture worth a thousand words? An empirical study of image content and social media engagement. *Journal of Marketing Research*, 57(1), 1–19.
5. Mohammad, A.A., Elshaer, I.A., Azazz, A.M., Kooli, C., Algezawy, M., & Fayyad, S. (2024). The influence of social commerce dynamics on sustainable hotel brand image, customer engagement, and booking intentions. *Sustainability*, 16(14), 6050.
6. Moran, G., Muzellec, L., & Johnson, D. (2019). Message content features and social media engagement: evidence from the media industry. *Journal of Product and Brand Management*, 29(5), 533–545.
7. Reddy, M.A.S., & Prakash, C. (2024). Sentiment analysis of social media networking sites: a comparative study on user engagement and public opinion.
8. van der Harst, J.P., & Angelopoulos, S. (2024). Less is more: Engagement with the content of social media influencers. *Journal of Business Research*, 181, 114746.